



الجمهورية العربية السورية

جامعة دمشق

كلية الهندسة المعلوماتية

اختصاص الذكاء الصنعي

## مادة معالجة اللغات الطبيعية NLP

الفصل الأول 2025/2026

### الوظيفة الأولى

**الوظيفة الأولى: مسألة تصنيف الأسئلة الطبية وترقيم النصوص العربية**

### Arabic Medical Question Classification and Punctuation Prediction

الهدف من الوظيفة والفائدة المرجوة للطالب من إنجازها

1. التعامل مع النصوص العربية.
2. فهم مسألة وضع علامات الترقيم الصحيحة في نص عربي.
3. فهم مسألة تصنيف الأسئلة الطبية
4. تحويل البيانات لفهم محتواها بدون قراءتها كلها.
5. تنظيف وتوحيد النصوص، ودراسة تأثير عمليات المعالجة المسبيقة على دقة حل المسألة.
6. تمثيل النصوص باستخدام طرق مختلفة للتمثيل الشعاعي (Vectorization).
7. حل مسألة التصنيفات باستخدام خوارزميات التصنيف الآلي المختلفة (Classification).
8. حل مسألة ترقيم النص العربي باستخدام خوارزميات تنميط السلسل المختلطة (Sequence Labeling).

ملاحظة: اعتمد على وضع الملاحظات على تحقيق الطلبات إن كان لشرح الأكواد التي حفقت بها المطلوب أو ملاحظاتك على الخرج، واحرص أن تكون ملاحظاتك باللغة العربية الفصحى السليمة. أيضاً لا تنسى، حافظ على نظافة الكود لتسهيل قراءته (وبالتالي تسهيل حصولك على علامة جيدة 😊).

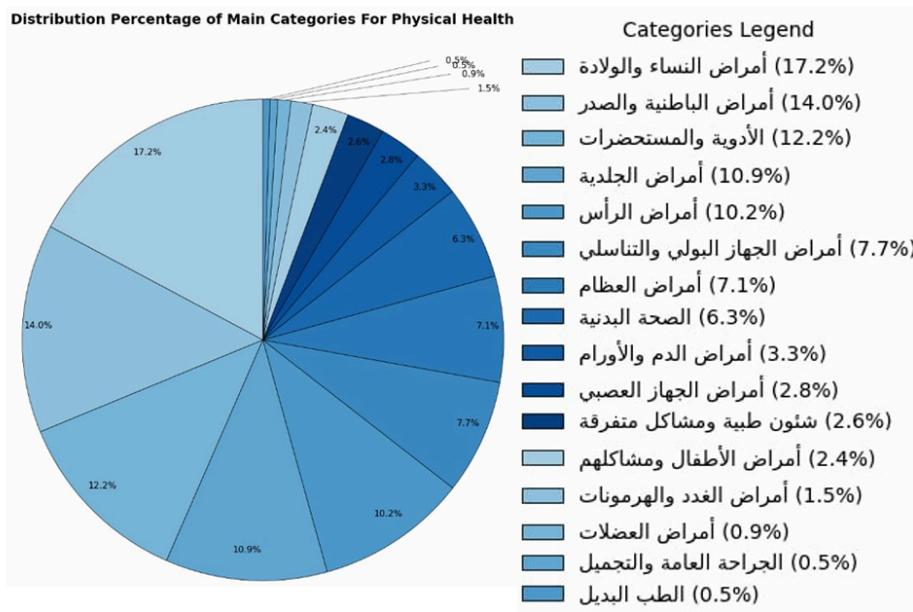
## نص الوظيفة

### المسألة الأولى: مسألة تصنيف الأسئلة الطبية

تقديم العديد من المواقع منصات للإجابة عن أسئلة المستخدمين في مجالات مختلفة، من هذه الموقع المواقع الطبية التي يجب فيها أطباء متخصصون عن استفسارات السائلين عبر مسائل طبية مختلفة.

يطرح السائل سؤاله عادة دون أن يعرف الاختصاص الدقيق الذي ينتمي له سؤاله، ويكون من مهمة القائمين على الصفحة توجيه السؤال للطبيب المختص.

لتسهيل العملية وتسريع هذه العملية سنقوم ببناء مصنف يقوم بتحديد الاختصاص الدقيق للمسألة المطروحة، بناءً على قاعدة بيانات "شفاء" الموجودة على [الرابط](#) التي تحتوي على أسئلة وأجوبة طبية مصنفة إلى عدة تصنفيات هرمية، استخدام عمود السؤال "شفاء المصنف، واعتمد التصنيف الرئيسي فقط".



### المطلوب:

قم ببناء ومقارنة عدة نماذج لتصنيف السؤال. ابدأ بتحليل البيانات EDA، وقم بكتابة مجموعة توابع لإجراء عمليات المعالجة المسبقة على النص وذلك لاختبار تأثيرها لاحقاً على المصنف،

قم ببناء مصنف للبيانات ذلك بثلاث طرق (يمكنك الإضافة على هذه الطرق في حال وجدت حلاً أفضل):

- الطريقة الأولى: اعتمد على حل المسألة باستخدام طرق التمثيل الشعاعي للنص (مثل TF-IDF) خوارزميات التعلم التلقائي التقليدية.

- الطريقة الثانية: باستخدام خوارزميات التعلم العميق مع تمثيل embedding مناسب، قم باختبار أثر استخدام تضمينات مدربة مسبقاً على الأداء،

- الطريقة الثالثة: باستخدام طرق نقل المعرفة (transfer learning) بالاعتماد على نماذج لغوية مدربة مسبقاً.

#### ملاحظات:

استخدم الـ notebook المرفق لتحميل البيانات، استخدم في بناء التموذج وضبط المعاملات مجموعة علامة الترقيم والتحقيق، استخدم مجموعة الاختبار لعرض النتائج النهائية فقط، انتبه من تسريب البيانات.

### المأسأة الثانية: مسألة ترقيم نص عربي

تعتبر علامات الترقيم مؤشرات مهمة في النصوص لتحديد الجمل مكتملة المعنى، وتخالف علامات الترقيم بحسب المعنى المراد من الجملة فهناك الفاصلة "،" والنقطة ".،" وإشارة الاستفهام "?،" ... الخ. وتأتي أهمية مسألة تحديد علامة الترقيم المناسبة من كونها مسألة جزئية من تطبيقات عديدة لها مثل تحليل وتركيب الكلام وكعملية معالجة لاحقة في مسألة الترجمة، حيث تساهمن في جعل النص المستخرج من الكلام قابل للقراءة والفهم أكثر.

في هذه الجزء سنقوم بحل مسألة ترقيم النص المكتوب باللغة العربية، اعتماداً على مجموعة البيانات [Arabic punctuation dataset](#) وهي عبارة عن مجموعة ضخمة من النصوص بالعربية الفصحى والمخصصة لتدريب التعلم الآلي على تحديد حدود الجمل والتنبؤ بالترقيم.

#### المطلوب

أولاً، قم بتنزيل مجموعة البيانات من [الرابط](#)، حيث سنقوم باعتماد البيانات المتوفرة في الملف لتدريب المأسأة.

سنعتمد علامات الترقيم التالية كهدف للمأسأة: Question marks، Colons، Commas، Semicolons، Exclamation (أو [mark](#))، Full stops وذلك بأشكالها المختلفة (قم بتوحيد أشكالها قبل البدء بالمسألة)

لإنشاء بيانات التدريب قم بإزالة العلامات من النص ليصبح لديك النص بدون علامات الترقيم.

بداية قم بإجراء تحليل لمجموعة البيانات، قم بكتابة مجموعة توابع للمعالجة المسألة لدراسة أثرها على المصنفات، مستعيناً بشرح البيانات الموجود في الورقة البحثية.

ستتعامل مع المأسأة كمسألة تتميّط السلاسل sequence labeling. بحيث يكون الدخل سلسلة الكلمات الموافقة للنص ويكون الخرج سلسلة علامات الترقيم التي تلي كل كلمة، نلاحظ المثال في الصورة المرفقة أدناه أن نص الدخل "أكل الولد الخبر، وشرب الماء" ، في البداية تم تقطيع النص إلى كلمات (والذي يفترض أن يكون خالٍ من علامات الترقيم)، وعندها يكون الخرج أيضاً سلسلة تحوي أرقام علامة الترقيم الموافقة فنلاحظ أن الكلمة الأولى "أكل" توافق الرقم 0 والذي يعني عدم ورود علامة ترقيم، وكذلك للكلمة الثانية، بعد ذلك في الكلمة "الخبر" تقابل علامة الترقيم ذي الرقم 2 والذي يشير إلى الفاصلة "،". إذاً سيكون الدخل هو مصفوفة الكلمات (من نمط string) والخرج سلسلة معرفات علامات الترقيم التي تلي كل كلمة (من نمط معطيات رقمية). نسمى هذه المأسأة عادة sequence-2-sequence.

باعتبار أن مجموعة البيانات غير منمنطة ستعمل على تتميّطها مستخدماًتابع تقطيع مناسب للنموذج الذي تختبره، ومعتمداً على آلية الاستخراج الموضحة في الجدول 1 المرفق أدناه.

Original text	أكل الولد الخبز، وشرب الماء.
No punct. tokenized text	[أكل, الولد, الخبز, وشرب, الماء]
Encoded label	.‘—
Numerical label	[1,0,2,0,0]

جدول 1: يوضح توصیف دخل وخرج مسأله ترقیم النص العریبي ([Wazrah .et.al, 2025](#))<sup>21</sup>

قم بمقارنة عدّة طرق لبناء النماذج

- الطريقة الأولى باستخدام خوارزمیات التعلم العمیق مع تمثیل embedding مناسب، قم باختبار أثر استخدام تضمینات مدربة مسبقاً على الأداء،
- الطريقة الثانية باستخدام طرق نقل المعرفة (transfer learning) بالاعتماد على نماذج لغوية مدربة مسبقاً.

هام: اكتب تابعاً يأخذ بيانات اختبار (مجموعة نصوص -من عدة أسطر قد تكون طويلة- مع علامات ترقیم) ويقوم بإزالة علامات الترقیم منها ثم يحسب أداء أفضل نموذج على بيانات الاختبار مع طباعة النتائج بشكل واضح، هذه التابع مهم لتقییم مسألك ولن تقبل المسأله بدونه.

استخدم المصنف في تصنیف الإجابات على الأسئلة الطبیة (القسم الأول من الوظيفة) في قسم "أمراض الباطنیة والصدر"، قم بحساب الأداء. هل تعتقد أن النموذج قد عُمِّ جيداً على المجال الطبی؟

قم بإعادة تدريب النموذج مع إدخال البيانات الطبیة من باقي التصنیفات على النموذج ثم احسب معايیر التقییم لكل من الصنوف. هل تحسن الأداء؟

## ملاحظات

لتتنزيل البيانات على google colab مباشرة عبر رابط يمكنك الاستعانة بالأداء [curlwget](#)، اقرأ عنها للتتعلم كيف يمكنك استخدامها.

في حال كان حجم البيانات للتدريب كبيراً (يستهلك وقتاً طويلاً) قم بالتدريب على جزء من البيانات فقط اعتمد البيانات كاملة لتدريب نموذجك الأفضل.

قم بتنقییم البيانات إلى مجموعتي تدريب وتحقیق، وسيتم تزویدك ببيانات اختبار عند تسليم الوظيفة لحساب الأداء عليها.

<sup>1</sup> Asma Ali Al Wazrah, Afrah Altamimi, Hawra Aljasim, Waad Alshammari, Rawan Al-Matham, Omar Elnashar, Mohamed Amin, and Abdulrahman AlOsaimy. 2025. [Evaluation of Large Language Models on Arabic Punctuation Prediction](#). In *Proceedings of the 1st Workshop on NLP for Languages Using Arabic Script*, pages 144–154, Abu Dhabi, UAE. Association for Computational Linguistics.

تعليمات العمل:

- لا تنسى المرور بجميع مراحل مسألة معالجة اللغات الطبيعية.
- يشترك الطالب حل الوظيفة في مجموعة مكونة من 5 طلاب فقط (لا أكثر ولا أقل) ولا جدال في العدد المسموح.
- يقوم طالب واحد فقط من المجموعة **بتسجیل أسماء الطالب والمسألة التي سيعملون عليها على الرابط** خلال يومين من **موعد صدور الوظيفة**. لن **لن وألف لن يُسمح** بتغيير أفراد المجموعة في الوظائف القادمة.
- تحتاج الوظيفة لتنهي في الوقت المحدد تعاون جميع أفراد المجموعة.
- ينقسم طلاب كل مجموعة إلى فريقين، الأول مؤلف من 2 طلاب لحل المسألة الأولى (مسألة التصنیف)، والفريق الثاني من 3 طلاب لحل المسألة الثانية (ترقیم النص العرّبی). يمكن لطلاب المجموعة الواحدة التعاون فيما بينهم على حل المسألتين لكن كل طالب يأخذ علامة الوظيفة على المسألة الخاصة به فقط.

تعليمات حل الوظيفة:

- يتم تسلیم notebook واضح ونظيف لكل مسألة من المسائل يحتوي حل المسألة بكامل خطواتها ابتداءً من تحلیل مجموعة البيانات وانتهاءً بعرض جدول مقارنة النماذج الذي ستعتمد عليه لاختیار النموذج الأفضل الذي ستحصل على علامة دقته. في المسألة الثانية قم بتسلیم notebook إضافي يحوي تابع لاختبار النموذج الأفضل الذي قمت باختیاره، بحيث يكون اسم التابع evaluate\_best\_model ويمرر وسيطر اربط مجموعة الاختبار ووسیط رابط النموذج المدرّب. ببدأ التابع بتعريف بنية النموذج ثم تحميل الأوزان من الرابط المرفق ثم تحميل مجموعة الاختبار وأخيراً تقييم النموذج وفق معايير تقييم نماذج التصنیف. ويعيد التابع قيمة دقة النموذج وفق المعيار Fscore الذي سيتم اعتماده للمفضلاة بين حلول الطلاب وإعطاء العلامة.
- يجب أن يرفق كل notebook بخلايا نصية لشرح الكود قبل خلية الكود وخليه نصية أخرى لكتابه ملاحظات الطلاب على خرج خلية الكود بعدها، ولن يصحح أي كود مالم يرفق بهاتين الخلتين النصيتين.
- اختر لأسماء النماذج وعمليات المعالجة أسماء واضحة ومعبرة، في حال عدم وجود أي إضافة قم بكتابه .none.
- قم ب تخزين نتائج كل نموذج تبنيه والنتائج النهائية في كياني فهرس dictionary، يتّألف كل منها من 7 مفاتيح، قيمة كل مفتاح مصفوفة list اتضاف إلى الفهرس بعملية append. المفاتيح كالتالي:
  - number\_step: يعبر عن رقم النموذج.
  - name\_model: ويعبر عن خوارزمية التدريب.
  - features: ويعبر عن شكل الدخل أو سمات النموذج.
  - parameters\_model: يحتوي أسماء البارامترات الفائقة hyperparameters المعدلة وقيمها الجديدة وفي حال عدم تعديل بارامترات النموذج اتضاف كلمة default.
  - methods\_preprocessing: يعبر عن خطوات المعالجة التي قمت بها قبل التدريب.
  - accuracy: يعبر عن مقدار دقة الاختبار.
  - F-score: ويعبر عن مقدار دقة التصنیف على بيانات الاختبار.
- انتبه أنه هناك dictionary يضاف إليه نتائج طلبات التدريب، وهناك جدول نهائي للنماذج الأفضل من كل طلب منها.
- لن تقبل الوظيفة بدون طباعة جدول مقارنة النماذج.
- استخدم معايير F-score بالإضافة إلى الدقة Accuracy. وأيضاً قم بطباعة مصفوفة التعارضات confusion matrix لدراسة تضارب الصفوف مع بعضها

13- أي خطوة تقوم فيها (مثلاً نوع معين من المعالجة المسبقة) يجب عليك أن تثبت فائدته لعملية التدريب وذلك من خلال التجربة.

#### تعليمات تسليم الوظيفة، وآلية التقييم:

14- تاريخ التسليم: الأحد 21 كانون الأول 2024.

15- بالنسبة للمسألة الثانية يعطى الطالب مجموعة اختبار منفصلة يوم المقابلة لتقدير النموذج الأفضل الذي قام ببنائه، ويحصل الطالب على جزء من العلامة على حل الوظيفة والجزء الآخر دقة النموذج على مجموعة الاختبار،

16- ستقوم بتسليم ملفي كود ورابط النموذج الأفضل المدرّب

17- قم بتسمية ملف كل مسألة بأسماء الطلاب المشتركون بحدها، وأرفق أسماء الطلاب أيضاً كتعليق ضمن الملفين باللغة العربية، وأي ملف لا يحقق هذا المعيار لن يُصحح.

18- تأكّد من عدم طباعة كامل البيانات في ملف ipynb، تقادياً لتجاوز حجم الملف الحد المسموح 10M.

19- تأكّد من تنفيذ جميع التعليمات البرمجية في كل خلية.

20- تأكّد أن الملفين قابلين لفتح القراءة بوضوح وأن حجمهم لا يتتجاوز 10M.

21- قم برفع الملفين ipynb دون ضغط، على رابط تسليم الوظيفة.

#### تعليمات عامة:

22- لا ننصح أبداً باستخدام أي نموذج لغوي لكتابة الكود عنك، وفي حال كان هناك أي مؤشر لعدم فهمك لكل جزئية صغيرة في الكود أو عدم قدرتك على تعديله، ستخسر علامته مباشرةً بدون أي نقاش.

23- ننصح باستخدام google colab في تدريب النماذج والتعامل مع البيانات عوضاً عن التنفيذ المحلي على جهازك

24- **تحذير:** عند وجود أي تشابه بين وظيفتي مجموعتين ستخسر المجموعتان العلامة معاً دون مراجعتها (هذا خبر وليس تهديد عزيزي الطالب).

مع أمنياتنا لكم التوفيق

مدرس المادة